

Aprovisionamiento de infraestructura IaaS/PaaS y carga analítica en Amazon RDS

1. Objetivo y alcance

Esta práctica extiende el pipeline de ingesta de la Actividad 2 con una capa de almacenamiento estructurado. Los datos de cafeterías de Teusaquillo, extraídos de Foursquare Places API y depositados en la zona cruda de Amazon S3, se leen desde un entorno JupyterHub sobre Amazon EC2, se transforman con pandas y se persisten en Amazon RDS PostgreSQL mediante INSERT parametrizados. La pregunta de negocio que orienta el análisis es dónde se concentra la oferta y qué tan saturado está el mercado en cada franja de distancia, con el fin de identificar zonas de menor densidad competitiva.

2. Arquitectura desplegada

Componente	Servicio y configuración	Rol en la arquitectura
Zona cruda	Amazon S3 — raw_zone/cafeterias/	Almacenamiento del dato original sin transformar
Procesamiento	Amazon EC2 t3.medium, Ubuntu 24.04, TLJH	Entorno colaborativo de análisis (IaaS)
Almacenamiento estructurado	Amazon RDS PostgreSQL, db.t3.micro	Motor relacional administrado (PaaS)
Cliente de base de datos	DBeaver Community	Ejecución del DDL y verificación

3. Modelo de datos

La tabla `cafeterias_teusaquillo` almacena 46 establecimientos con doce atributos. Las decisiones de tipificación responden a la naturaleza de cada dato:

Atributo	Tipo	Justificación
<code>fsq_place_id</code>	VARCHAR(40) PK	Identificador natural provisto por Foursquare
<code>latitude / longitude</code>	DOUBLE PRECISION	Precisión decimal requerida por coordenadas WGS84
<code>distance_m</code>	INTEGER	Magnitud discreta en metros
<code>categories / category_ids</code>	JSONB	Atributo multivaluado; evita una tabla puente
<code>address</code>	TEXT	Longitud variable; admite nulos
<code>fecha_carga</code>	TIMESTAMP	Trazabilidad del proceso de carga

Justificación del uso de JSONB

Un establecimiento puede pertenecer a varias categorías a la vez: nueve locales combinan cafetería con panadería, tienda de bicicletas o coworking. La alternativa normalizada exigiría dos tablas adicionales y operaciones JOIN para un atributo que proviene de una taxonomía externa y no requiere integridad referencial propia. JSONB preserva la estructura multivaluada y, con un índice GIN, habilita consultas de contención eficientes: `WHERE categories @> '{"Bakery"}'` recupera los establecimientos que también operan como panadería. La decisión se revisaría si las categorías requirieran atributos propios o si el volumen creciera en un orden de magnitud.

El modelo entidad-relación completo, con restricciones de dominio e índices, se presenta en el Anexo (Figura 1).

4. Implementación del pipeline

Lectura. El objeto se descarga a memoria con `io.BytesIO`, sin escritura intermedia en disco. Las credenciales de S3 no se declaran en el código: la instancia las obtiene del rol `IAM LabInstanceProfile`, eliminando las llaves estáticas.

Transformación. Se normalizan los nombres de columna, se aplica tipificación explícita (`float64` para coordenadas, `Int64 nullable` para la distancia) y se convierten a listas los campos de categorías, que el CSV entrega como cadenas separadas por comas. Un control de calidad previo verifica nulos, duplicados por clave primaria y coordenadas fuera de rango.

Carga. Las inserciones usan consultas parametrizadas con marcadores `%s`, delegando el escapado al driver `psycopg2`: esto previene la inyección SQL y resuelve casos como el establecimiento `Tostao'`, cuyo apóstrofo rompería una sentencia concatenada. `execute_batch` agrupa las sentencias en lotes de cincuenta y la cláusula `ON CONFLICT DO UPDATE` hace la carga idempotente.

5. Resultados analíticos

Las tres estadísticas se calculan con sentencias SQL ejecutadas sobre el propio motor relacional.

5.1 Composición de la oferta

Categoría principal	Establecimientos	Participación
Coffee Shop	23	50,0 %
Café	21	45,7 %
Bicycle Store	1	2,2 %
Bakery	1	2,2 %
Total	46	100 %

Las dos categorías propiamente cafeteras concentran el 95,7 % de la oferta; los dos casos restantes son establecimientos cuya actividad principal es otra pero que prestan servicio de café.

5.2 Distribución de la distancia al punto de consulta

Media	Desv. est.	Mínimo	Q1	Mediana	Q3	Máximo
1 338 m	473 m	370 m	1 180 m	1 329 m	1 527 m	2 234 m

La coincidencia entre media (1 338 m) y mediana (1 329 m) indica una distribución simétrica. El rango intercuartílico de 347 metros revela una concentración notable: la mitad central de los establecimientos cabe en la franja de 1 180 a 1 527 metros.


5.3 Diversificación del modelo de negocio


Número de categorías	Establecimientos	Participación
1 (formato puro)	37	80,4 %
2 (híbrido)	8	17,4 %
3 (híbrido)	1	2,2 %

El 19,6 % declara más de una categoría. El análisis de frecuencia sobre el arreglo JSONB muestra que la combinación dominante es cafetería con panadería (cinco casos), seguida por tienda de bicicletas y coworking con un caso cada una: la panadería es la vía de diversificación establecida en la zona.

5.4 Visualización

El histograma de distancias, con las líneas de media y mediana, responde a la pregunta de negocio: las franjas de baja frecuencia señalan segmentos con menor densidad competitiva. El mapa de calor incluido en el notebook complementa la lectura al contar establecimientos por celda del territorio.





6. Consideraciones de seguridad

La implementación aplica tres capas independientes. Ninguna credencial está escrita en el código: las variables sensibles residen en un archivo .env local al servidor, excluido del control de versiones. El acceso a S3 se resuelve mediante el rol IAM LabInstanceProfile, lo que evita llaves estáticas y delega su rotación a AWS. Y el grupo de seguridad de RDS restringe el puerto 5432 a la IP del equipo de desarrollo y a las instancias EC2 del mismo grupo, de modo que un tercero con las credenciales no podría conectarse desde otra red. A ello se suma el uso de consultas parametrizadas en toda escritura.

7. Limitaciones y dificultades encontradas

La variable distance_m mide la separación respecto al punto central de la consulta a la API, no al centroide geográfico de la localidad; las conclusiones sobre concentración reflejan en parte la geometría de la búsqueda y no solo la distribución real del mercado.

Se presentaron tres incidencias durante el despliegue. La instancia RDS se creó sin acceso público, lo que producía timeout; el diagnóstico surgió al observar que el endpoint resolvía a una dirección privada del rango 172.31.x.x. El grupo de seguridad solo admitía el puerto 5432, por lo que hubo que habilitar el 22 y el 80. Y la caducidad de la sesión del laboratorio detuvo las instancias en mitad del trabajo, lo que obliga a descargar los entregables de forma incremental.

8. Conclusiones

El pipeline S3 → transformación → RDS se ejecuta de extremo a extremo de forma reproducible, sin escritura intermedia en disco ni credenciales embebidas. La verificación desde DBeaver confirma la persistencia de los 46 registros con la estructura JSONB intacta, y el modelado con índice GIN resulta adecuado para un atributo multivaluado de origen externo.

En términos de negocio, la oferta de Teusaquillo está dominada por dos categorías y muestra una concentración geográfica marcada (RIQ de 347 m). El 19,6 % de formatos híbridos, con la panadería como combinación predominante, señala una vía de diferenciación ya explorada por el mercado local.

9. Anexo

Modelo entidad-relación

Modelo Entidad-Relacion · cafeterias_teusaquillo

Amazon RDS PostgreSQL · Actividad 3 - Herramientas de Computación en la Nube

cafeterias_teusaquillo				46 registros
PK	fsg_place_id	VARCHAR(40)	Identificador foursquare	
	name	VARCHAR(255)	Nombre comercial NOT NULL	
	latitude	DOUBLE PRECISION	Latitud WGS84 NOT NULL	
	longitude	DOUBLE PRECISION	Longitud WGS84 NOT NULL	
	distance_m	INTEGER	Distancia al centro (m)	
IX	primary_category	VARCHAR(100)	Categoría principal	
	primary_category_id	VARCHAR(40)	Id de categoría principal	
GIN	categories	JSONB	Arreglo de categorías	
	category_ids	JSONB	Arreglo de ids de categoría	
	address	TEXT	Dirección (admite nulos)	
IX	localidad	VARCHAR(100)	Localidad validada	
	fecha_carga	TIMESTAMP	DEFAULT CURRENT_TIMESTAMP	

PK Clave primaria **IX** Índice B-tree **GIN** Índice GIN sobre JSONB

Restricciones: chk_latitude (-90..90) · chk_longitude (-180..180) · chk_distancia (>= 0) | Índice compuesto (latitude, longitude) para filtros geoespaciales

Figura 1. Modelo entidad-relación de la tabla `cafeterias_teusaquillo`, con tipos de datos, restricciones de dominio e índices.

Evidencia de apagado de instancias

Ambas instancias EC2 (servidor de JupyterHub y servidor de ingesta de la actividad anterior) fueron detenidas al finalizar la práctica, junto con la instancia RDS.

The image displays two screenshots of the AWS Management Console, showing the process of stopping EC2 instances.

Top Screenshot: Instance i-00805463b70939441 (jupyterhub-server)

- Instance ID:** i-00805463b70939441
- Instance state:** Stopping
- Public IPv4 address:** 184.193.18.73
- Private IPv4 addresses:** 172.31.9.42
- Public DNS:** ec2-184-193-18-73.compute-1.amazonaws.com
- Instance type:** t3.medium
- VPC ID:** vpc-0bc470751972263f5

Bottom Screenshot: Instance i-06ce057782984d031

- Instance ID:** i-06ce057782984d031
- Instance state:** Stopping
- Public IPv4 address:** 3.91.46.186
- Private IPv4 addresses:** 172.31.18.234
- Public DNS:** ec2-3-91-46-186.compute-1.amazonaws.com
- Instance type:** t3.micro
- VPC ID:** vpc-0bc470751972263f5

aws [Search] [Alt+S] United States (N. Virginia) Account ID: 1389-8584-2693 voclabs/user4915470=Efren_Alexander_Granados_L...

Aurora and RDS > Databases > cafeterias-db

Aurora and RDS

- Dashboard
- Databases**
- Query editor
- CloudWatch Database Insights
- Snapshots
- Exports in Amazon S3
- Automated backups
- Reserved instances
- Proxies
- Subnet groups
- Parameter groups
- Option groups

Stopping database cafeterias-db is in progress

cafeterias-db [Refresh] [Edit] Modify Actions

Summary

DB identifier cafeterias-db	Status ⌚ Stopping	Role Instance	Engine PostgreSQL
CPU -	Class db.t3.micro	Current activity 0.00 sessions	Region & AZ us-east-1a

Recommendations
2 Informational

Connectivity & security | Monitoring | Logs & events | Configuration | Zero-ETL integrations

https://awsacademy.instructure.com/courses/187294/modules/items/18514731

aws academy ALLv2EN-US-LT113-187294 > Modules > AWS Academy Learner Lab > Launch AWS Academy Learner Lab

Home | Modules | Discussions | Grades | Courses | Lucid (Whiteboard) | Notebook

Account | Dashboard | Calendar | Inbox | History | Help

AWS Used \$0.2 of \$50 00:00 Start Lab End Lab AWS Details Readme Reset

eee_h_676470@runweb252495:~\$

Learner Lab

Información general sobre el entorno
Navegación del entorno
Acceso a la Consola de administración de AWS
Restricción de región
Uso de servicios y otras restricciones
Uso del terminal en el navegador
Ejecución de comandos de la CLI de AWS
Uso del AWS SDK para Python
Preservación del presupuesto
Acceso a instancias de EC2
Acceso mediante SSH a instancias de EC2

Previous Next

Evidencias adicionales (Dbeaver)

DBeaver 26.2.1 - <postgres> Script-1

Archivo Editar Navegar Buscar Editor SQL Base de datos Ventana Ayuda

Conexiones Proyectos

Filter connections by name

postgres cafeterias-db.ckuuladugdy5.us-east-1.rds.

<postgres> Script-1

```
-- SELECT column_name, data_type, is_nullable  
-- FROM information_schema.columns  
-- WHERE table_name = 'cafeterias_teusaquillo'  
-- ORDER BY ordinal_position;  
  
SELECT column_name, data_type  
FROM information_schema.columns  
WHERE table_name = 'cafeterias_teusaquillo'  
ORDER BY ordinal_position;  
  
SELECT COUNT(*) FROM cafeterias_teusaquillo;
```

cafeterias_teusaquillo 1

count
46

Valor 46

Get insights based on your data: ask AI to build a query for your database or upload a file you want to analyze.

Press Ctrl+Intro to submit your query

Select AI profile Select model

GMT-05:00 es Editable Inserción inteligente 101 : 1 : 4990 Set 0 | 0

DBeaver 26.2.1 - <postgres> Script-1

Archivo Editar Navegar Buscar Editor SQL Base de datos Ventana Ayuda

Conexiones X Proyectos AI SQL Confirmar Revertir Auto postgres public@postgres

Filter connections by name

postgres cafeterias-db.ckuuladugdy5.us-east-1.rds.

<postgres> Script

```
-- select column_name, data_type, is_nullable
-- from information_schema.columns
-- where table_name = 'cafeterias_teusaquillo'
-- order by ordinal_position;

SELECT column_name, data_type
FROM information_schema.columns
WHERE table_name = 'cafeterias_teusaquillo'
ORDER BY ordinal_position;

SELECT COUNT(*) FROM cafeterias_teusaquillo;
SELECT name, primary_category, categories FROM cafeterias_teusaquillo LIMIT 10;
```

cafeterias_teusaquillo 1

	name	primary_category	categories
1	Juan Valdez Café	Coffee Shop	["Coffee Shop"]
2	Tostao'	Coffee Shop	["Coffee Shop", "Baker"]
3	Café Oma	Coffee Shop	["Coffee Shop"]
4	Juan Valdez Café	Coffee Shop	["Coffee Shop"]
5	Juan Valdez Café	Coffee Shop	["Coffee Shop"]
6	Juan Valdez Café	Coffee Shop	["Coffee Shop"]
7	Galería Café Libro 45	Café	["Café"]
8	Tempo Cycling	Coffee Shop	["Coffee Shop"]
9	Café Camerino	Coffee Shop	["Coffee Shop"]
10	Vereda Central ParkW	Café	["Café"]

Valor X

Text

Juan Valdez Café

Get insights based on your data: ask AI to build a query for your database or upload a file you want to analyze.

Press Ctrl+Intro to submit your query

Select AI profile Select model

GMT-05:00 es Editable Inserción inteligente 101:80:5069 Set: 0 | 0

DBeaver 26.2.1 - <postgres> Script-1

Archivo Editar Navegar Buscar Editor SQL Base de datos Ventana Ayuda

Conexiones X Proyectos AI SQL Confirmar Revertir Auto postgres public@postgres

Filter connections by name

postgres cafeterias-db.ckuuladugdy5.us-east-1.rds.

<postgres> Script

```
SELECT column_name, data_type
FROM information_schema.columns
WHERE table_name = 'cafeterias_teusaquillo'
ORDER BY ordinal_position;

SELECT COUNT(*) FROM cafeterias_teusaquillo;
SELECT name, primary_category, categories FROM cafeterias_teusaquillo LIMIT 10;

SELECT name, categories
FROM cafeterias_teusaquillo
WHERE categories @> ["Bakery"];
```

cafeterias_teusaquillo 1

	name	categories
1	Tostao'	["Coffee Shop", "Bakery"]
2	Canela Bakery C&T	["Café", "Bakery"]
3	Panadería La Isabella	["Coffee Shop", "Bakery"]
4	Tostao'	["Coffee Shop", "Bakery"]
5	Vasconia	["Bakery", "Café", "Coffee Shop"]

Valor X

Text

Tostao'

Get insights based on your data: ask AI to build a query for your database or upload a file you want to analyze.

Press Ctrl+Intro to submit your query

Select AI profile Select model

GMT-05:00 es Editable Inserción inteligente 105:34:5160 Set: 0 | 0